

NN의 역사

신경망

1957년 Frank Rosenblatt가 Mark I Perceptron machine을 개발

- 최초의 퍼셉트론 기계

1960년 Widrow와 Hoff가 Adaline and Madaline 개발

- 최초의 Multilayer Perceptron Network

1986년 Rumelhart

- 역전파 제안, 신경망 학습 시작

2006년 Geoff Hinton과 Ruslan Salakhutdinow

- DNN 학습가능성

2012년 Hinton lab

- 음성인식 NN 성능 좋음
- ImageNet Classification에서 최초로 NN 사용, 결과 좋았다 -> Alexnet

CNN

1950년 Hubel과 Wiesel의 뉴런 연구

- topographical mapping
- 뉴런의 계층구조
- Simple cells -> Complex cells -> hypercomplex cells

- 빛의 방향 -> 움직임 -> 끝 점

1980년 neocognitron

- simple/complex cell 사용한 최초의 NN

1998년 Yann LeCun

- NN 학습을 위한 역전파와 gradient-based learning

2012년 Alex Krizhevsky

- CNN의 유행

CNN으로 할 수 있는 것

- 이미지 분류, Detection, Segmentation, 자율주행, 얼굴인식 사람추정, 자세 인식, 의학 진단, image captioning, 화풍 변경


CNN의 원리

Filter

Fully Connected Layer : 벡터를 펴서 내적 연산을 하는 방식

Convolutional Layer : 기존의 **structure**를 보존하며 계산. 하늘색 필터가 이미지 내를 슬라이딩 하며 공간적인 내적을 함. 모든 **depth**에 대해 내적이 진행되어야 하므로, 필터의 **depth**는 input의 **depth**와 항상 같다.

32x32x3 image




5x5x3 filter



Convolve the filter with the image
i.e. "slide over the image spatially,
computing dot products"


필터가 슬라이딩을 하면서 **output**을 뽑아내는 방법: 겹쳐놓고 내적하고, 슬라이딩해서 옆에서 계속 내적해서 **output activation map**의 해당 위치에 전달

Activation map의 차원 : 입력은 32x32, 출력은 28x28. 원하는 만큼 필터를 사용할 수 있음.

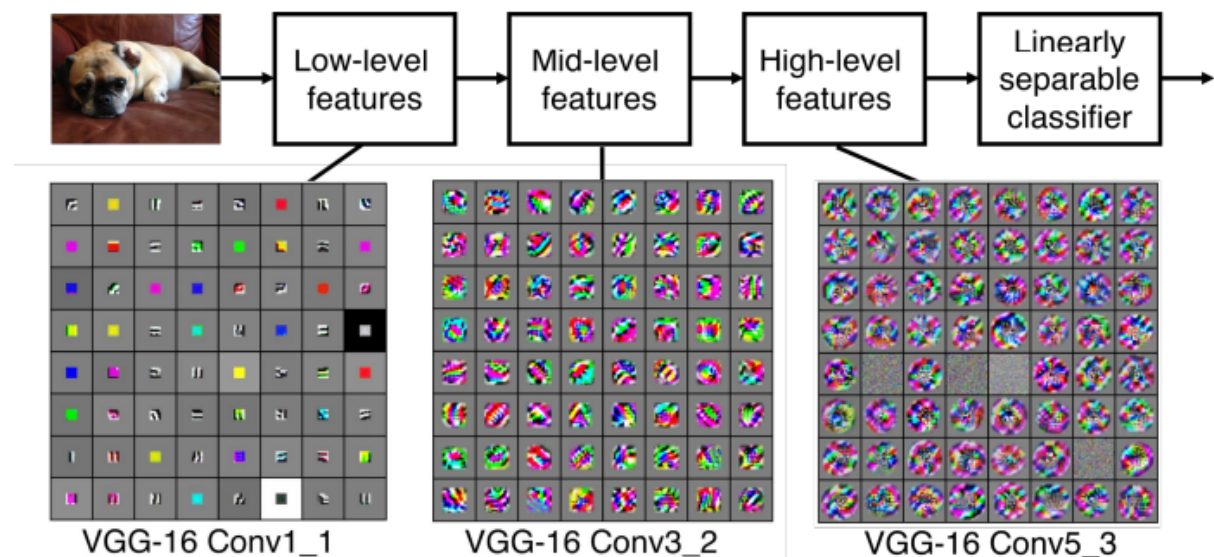


We stack these up to get a “new image” of size 28x28x6!

사이사이에 **activation**, **pooling** 등이 들어감. **layer**는 여러개의 필터를 가지고 있고, 각 필터마다 각각의 출력 **map**을 만듦. 여러 **layer**들을 거치면서 각 필터들이 계층적으로 학습 가능.



여러개의 **convolution layer**를 거치면서 단순한 구조에서 더 복잡한 구조로 찾아감. 각 **grid**는 하나의 뉴런(**filter**).



CNN은 input 이미지는 여러 layer들을 거치게 되고, 마지막에는 FC layer를 통해 score를 계산.

필터를 몇칸씩 움직일지를 stride로 정할 수 있음. 보통 input 사이즈와 슬라이딩 시 딱 맞아떨어지는 stride만을 이용.

Output size:
 $(N - F) / \text{stride} + 1$

입력의 차원: N

필터 사이즈: F

stride를 설정해 줌으로써 pooling과 같이 다운샘플링할 수 있고, 더 좋은 성능을 가져다주기도 함. 이는 activation map의 사이즈를 줄이는 것이고, 나중에 FC layer의 파라미터의 수가 줄어들게 된다.

zero-padding

In practice: Common to zero pad the border

0	0	0	0	0	0			
0								
0								
0								
0								

e.g. input 7x7
3x3 filter, applied with **stride 1**
pad with 1 pixel border => what is the output?

(recall:)
 $(N - F) / \text{stride} + 1$


코너의 값들이 적게 연산되는 것을 막아주고, 레이어들을 거치면서 입력의 사이즈가 줄어드는 것을 막아준다. 깊은 네트워크에서는 Activation map이 엄청나게 작아지게 되고, => 정보 없음. 항상 원본 이미지를 표현하기에 충분한 차원을 사용해야 한다.

위의 사진에서 출력은 $7 \times 7 \times (\text{필터의 개수})$. 각 필터가 입력의 모든 **depth**에 대해 내적을 수행한다.

ex)

Examples time:

Input volume: $32 \times 32 \times 3$
10 5×5 filters with stride 1, pad 2




Number of parameters in this layer?

-> 필터당 $5 \times 5 \times 3 + 1$ (bias)개의 파라미터 존재, 총 760개의 파라미터가 존재한다.

5×5 필터가 있다면 한 뉴런의 **Receptive field**가 5×5 라고 한다. **Receptive field**란 한 뉴런이 한 번에 수용할 수 있는 영역을 의미한다.

만약 총 5개의 필터를 아래와 같이 거쳤다면, 한 점에서 **depth** 방향으로 바라보면, 이 5개는 정확하게 같은 지역에서 추출된 서로 다른 특징이다. 즉, 공간적 의미를 그대로 가져갈 수 있다.




Pooling, ReLU

CNN에 들어가는 다른 Layer

Pooling Layer

- Representation들을 더 작고 관리하게 쉽게 해줌
- DownSample
- 공간적인 invariance
- Depth는 그대로 둠
- 차원 계산은 $(width-Filter)/Stride+1$
- 보통 padding 안함(코너 값 계산 못하는 경우 없다.)
- 2x2, 3x3, stride=2 많이 씀




Max Pooling

- 필터 크기와 stride 정하면 됨

- 필터 안에 가장 큰 값 고름

- 겹치지 않게 풀링



ReLU Layer

- 실제 방식과 가장 유사한 비선형함수

- 활성화할지 비활성화 할지 결정

- 가장 많이 사용