Lecture 4 | Introduction to Neural Networks

Backpropagation: a simple example


$$f(x, y, z) = (x + y)z$$

e.g. $x = -2$, $y = 5$, $z = -4$

$$q=x+y \hspace{0.5cm} rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz$$
 $rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$


Want: $\frac{\partial f}{\partial x}$, $\frac{\partial f}{\partial y}$, $\frac{\partial f}{\partial z}$



지난 강의에서 배운 gradient를 이용하여 가중치를 업데이트 시키는 과정 – backpropagation 역전파에 대한 간단한 예시로 알아봄.


x, y, z가 각각 f에 미치는 영향? 미분 (df/dx, df/dy, df/dz)

- => 바로 나오지 않는 경우 chain rule을 이용
- *. 이때, 덧셈은 미분값이 1이 나오고, 곱셈은 서로의 값이 나온다.




- local gradient: forward에서 구하는 그레디언트
- global gradient: backward에서 구하는 그레디언트

=> chain rule을 이용해 둘을 곱하여 gradient를 구한다.



: 또 다른 예시 - sigmoid

위에서부터 계산된 upstream gradient(빨강)와 local gradient(초록)를 곱해 gradient를 구함



- sigmoid gate = > 미분을 통해, (1-sigmoid)*sigmoid 이 경우 (0.73)*(1-0.73)으로 그레디언트를 구할 수 있음
- add gate: gradient distributor

local gradient가 1이기때문에, global * local = global

- max gate: gradient router

여러 값들 중 한가지(작은 값은 0이 되므로)만을 전해줌


- mul gate: gradient switcher

서로 값이 바뀜

*. 만일 노드가 여러개이면? 값을 더하고 벡터일 경우 자코비안(?) 행렬로 쓴다

[Neural Networks]

- 이전 Linear score function: f=Wx
- 2-layer Neural Network: f = W_2max(0, W_1x)
- 3-layer Neural Network: f = W_3max(0, W_2max(0,W_1x))




뇌의 뉴런: 자극이 들어오면 axon을 통해 다른 뉴런으로 들어가며 서로 영향을 줌


- -> input에 가중치를 곱해 활성화 함수를 통해 output axc로
- *. 단, 딥러닝의 신경망과 실제 뉴런은 다른 것임

[activation functions]

Activation functions




Leaky ReLU $\max(0.1x, x)$



Maxout

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$



- sigmoid를 비롯하여 다양한 활성화 함수가 있음
- ReLU를 가장 많이 사용함